COMP5583 Agentic Computing

Aria’s Sky Journal
三版本网站与智能体技术优化报告

中文版主报告 · 2026年10月28日

姓名：Xinyue Liu（化名：Aria）

项目：静态个人作品集与课程笔记检索演示

技术路线：V0 基线 · V1 In-context Few-Shot Learning · V2 Retrieval-Augmented Generation

公开版本：V0 https://liuxinyue84-sketch.github.io/ | V1 https://liuxinyue84-sketch.github.io/V1/ | V2 https://liuxinyue84-sketch.github.io/V2/

1. 项目目标与 V0 基线

本项目以“Aria’s Sky Journal”为主题，构建清新水彩天空风格的个人作品集。访客可以浏览首页轮播、个人简介与教育经历、项目及贡献、生活照片和视频，并通过 Guestbook
留言。页面还提供舒曼《梦幻曲》的手动播放/暂停按钮，以及课程笔记检索模块。

V0 是冻结基线，保留完整源码与静态资源，后续 V1 和 V2 均从冻结 V0 独立派生，避免技术优化之间相互污染。

基线主要交互

- 顶部导航切换 Home、Highlights、Projects、Life 和 Guestbook。
- 教育卡片可展开；项目支持分类、详情展开和收藏状态本地持久化。
- Life 区支持照片/视频预览；音乐默认需要用户点击，符合浏览器自动播放限制。
- 课程笔记模块在前端执行 BM25 检索，显示召回内容及来源；V0 不调用外部 LLM API。

提示词约束

初始构建指令约束了页面身份、低饱和蓝白水彩视觉、毛玻璃卡片、个人内容范围、桌面端交互和静态
HTML/CSS/原生 JavaScript 实现；同时要求保留个人教育、项目和兴趣内容，并对课程检索模块明确其证据边界。

2. V1：In-context Few-Shot Learning

V1 使用正式的上下文学习技术。输入不只是“改得更好看”的指令，而是加入组件结构、排版节奏和交互范式示例；模型只能学习界面模式，禁止复制示例中的个人信息和个人文案。

少样本示例的迭代记录

迭代 1–6（组件架构，8 个来源）： al-folio；Shaoyan Liu academic-homepage；Jiya Batra ArtPortfolio-jtc；Michael Kolesidis 个人站；Scrapbook Portfolio；Photography Wall；Korbinian Möller 模板；Hitesh Nandakumar 作品集。重点学习章节导航、作品卡、详情展开和能力展示。
迭代 7（骨架筛选，3 个采用）：
astro-bento-portfolio、vcard-personal-portfolio、zine-moskovskaya-excursia；另外 4 个候选（vivek9patel、LiveTerm、hackclub/scrapbook、Dopefolio）被弃用。
迭代 10（Life 图墙，7 个来源）： SmugMug、60 Minute Sites、mediagallery.org、master-addons masonry、Justified-Gallery、flickr-justified-gallery 等，用于比较 Grid、Collage、Justified、Masonry 和 Slideshow。
迭代 9、11、12：未加入新样本；迭代 12 复用 Korbinian Möller 的按需展开和 Hitesh Nandakumar 的能力可见模式。

结构性改动

- 将 V0 的平铺式页面骨架重构为左侧常驻档案栏与右侧内容窗口。
- 把首页、教育、项目和生活内容迁移到新的章节容器与可展开组件中。
- 保留 V0 的个人文字、项目事实和主要交互，重点改变组件架构而不是只改颜色。

Few-shot 的作用与证据

示例提供了“如何组织组件”的可观察模式：编号章节、内容窗口、项目故事卡、独立详情区和清晰的操作提示。模型据此生成了与 V0 肉眼可区分的页面结构；48
组内容一致性检查确认个人文本没有被示例内容覆盖。完整来源、筛选理由和每轮输入记录在 reference_patterns.md、few_shot_examples_revision7.md、gallery_pattern_sweep.md。

> 评估结果：V1 人工评分 85/100，独立 AI Judge 评分 85/100。相较 V0，主要提升来自结构清晰度、项目叙事组织和视觉一致性。

3. V2：Retrieval-Augmented Generation

V2 完全从冻结 V0 派生，只升级课程笔记问答模块。由于 GitHub Pages 是纯静态托管，V2 不保存 API 密钥，也不调用真实外部 LLM；它实现的是可审计、可演示的前端 RAG 工作流。

关键迭代过程

- 初版：前端 BM25 召回笔记段落，并在界面显示来源。
- 联动修复：检索到片段时必须生成答案；只有 0 条有效片段才显示统一的资料不足提示。
- 证据清洗：原始笔记改为默认折叠的参考材料，清理 KB 编号、Markdown 和 LaTeX 残留，隐藏内部 prompt。
- 相关性迭代：保留全部命中片段作证据，但加入标题门控、baseConceptScore、主题重排和噪声过滤，避免只因正文偶然出现关键词就进入答案。
-

答案质量：多片段综合成英文定义与解释分点，保留句末引用，并增加子句—来源匹配检查，避免跨主题公式混入。

RAG 流程

- 知识库：将课程笔记、论文和项目材料整理为带标题、段落和来源的结构化条目。
- 检索：对用户问题执行 BM25 关键词召回，保留全部命中片段用于证据折叠区。
- 答案：从有效相关片段中提炼英文总结，并在句末标注 [R1]、[R2] 等来源；没有有效材料时输出统一的不足提示。

访客界面

页面把 Answer 和 View Retrieved Reference Materials 分开。答案区呈现简洁的总起句和解释性分点；参考材料默认折叠，访客点击后可核对清洗后的原文和来源。

> V2 是前端抽取式/规则式演示，能够展示检索—筛选—引用—回退链路，但无法替代后端 LLM 的开放式语言生成。

4. 统一评估与结果

三个版本使用同一套四项指标：内容完整性与贡献清晰度（30%）、导航与任务完成（25%）、可读性与视觉一致性（25%）、交互稳健性（20%）。每项按 0/3/5 档位定义，再按权重换算为百分制。三个版本分别运行独立 AI Judge；Judge 会话不提供人工分数。V2 在补充公开端到端证据后重新运行 Judge，以下采用重测结果。

版本	人工评分	AI Judge	差异（AI-人工）
V0	76/100	81/100	+5
V1 Few-shot	85/100	85/100	0
V2-RAG	86/100	91/100	+5

结果解读

- V0 的 AI Judge 对内容与稳健性略高估，但因可见证据有限而下调可读性。
- V1 人工与 AI Judge 完全一致，说明其结构性改动有较完整的截图和 E2E 证据支持。
- V2 初次评分为 81/100；补充公开 RAG 与非 RAG 端到端证据后，重测提升至 91/100，导航任务分从 3 提升到 5。

分数不是唯一证据：报告同时保留截图、源码片段、E2E 日志、28-query/10-invariant 回归结果及版本哈希。

5. 结论、局限与可复现性

综合来看，V1 在 Few-shot 组件重构方面带来了最明显的整体体验提升；V2 则把课程问答从普通关键词检索推进为可解释的前端 RAG 演示。两项技术解决的问题不同，因此不应只用总分判断优劣：V1 强化页面结构与任务组织，V2 强化证据链、来源引用和无资料回退。

当前局限

- 三版本都依赖静态网页，不能安全地调用真实 LLM API，也没有后端代理。
- 视觉评分受截图视口影响；截图不能证明所有路径、持久化和异常状态。
- 部分历史 Trae 对话原文未导出，附录中的重建稿已明确标注，不能替代真实原始记录。
- V2 的非 RAG 项目、媒体和留言路径需要在最终提交前再做一次公开 URL 端到端复测。

归档与复现

website/V0、website/V1 与 task3/v2/website 分别保存三个独立版本；evaluation/ 保存 rubric、人工评分、AI Judge prompt、三个原始 Judge 输出、截图、测试结果和对比分析；prompt_appendix/ 保存版本提示词、few-shot 示例、RAG 检索记录、修改日志与失败尝试。所有材料可在本地用静态 HTTP 服务器打开，公开版本可通过本报告第一页 URL 访问。

> 最终提交前检查：确认 report.pdf、prompt_appendix.pdf、website/、evaluation/ 均已打包；确认 V0 文件哈希与冻结记录一致；确认三个 AI Judge 原始输出保持原样。

5. 评估标准、证据与版本对照

四项指标同时关注网页内容质量与访客任务完成。内容完整性评价个人经历、教育和项目贡献是否保留且清楚；导航与任务完成评价主要模块是否容易找到并使用；可读性与视觉一致性评价水彩背景、玻璃卡片、字号和层级；交互稳健性评价轮播、展开、收藏、音乐、留言和检索在正常及边界输入下是否稳定。

评分档位

- 0 分：关键内容或交互缺失，页面无法支持主要任务。
- 3 分：主要路径可用，但存在明显遗漏、误导、不可见提示或未验证的边界状态。
- 5 分：内容完整、任务路径清晰、视觉层级稳定，并有可重复运行证据支持。

三版本主要证据

- V0：冻结源码、导航/教育/项目/媒体/音乐测试；课程检索仍暴露关键词召回偏题问题。
- V1：独立 Few-shot 输入材料、组件重构日志、48 组内容一致性检查、35/35 E2E 检查和截图。
- V2：V0 谱系哈希、结构化知识库、28 条查询和 10 项不变量回归、RAG 截图与公开部署记录。

版本变化与取舍

V1 的收益主要来自界面结构与信息组织，代价是组件层级更复杂；V2 的收益主要来自检索证据、来源引用和统一回退，代价是静态前端不能进行真实开放式生成。两个版本都保留了个人内容，避免技术优化变成更换个人信息。

6. 结论、失败尝试与可复现性

V1 在 Few-shot 组件重构方面带来了最明显的整体体验提升；V2
则把课程问答从普通关键词检索推进为可解释的前端 RAG
演示。两项技术解决的问题不同，因此不能只用总分判断优劣：V1 强化页面结构与任务组织，V2
强化证据链、来源引用和无资料回退。

失败尝试与修正

- 早期 V1 仅进行颜色和间距微调，外观与 V0 差异过小；随后改为基于 few-shot 示例重构页面容器和章节导航。
- 早期 V2 把检索命中误当成答案依据，导致资料不足判断错误或答案混入噪声；随后加入标题门控、主题重排、片段相关性筛选和统一回退。
- 早期回答直接显示 prompt 或原始笔记；随后把 prompt
移入归档，把证据放入默认折叠区，并将答案改为带引用的英文摘要。

当前局限

- 三版本都依赖静态网页，不能安全调用真实 LLM API，也没有后端代理。
- 视觉评分受截图视口影响；截图不能证明所有路径、持久化和异常状态。
- 部分历史 Trae 对话原文未导出，附录重建稿不能替代真实原始记录。
- V2 的非 RAG 项目、媒体和留言路径需要最终提交前再做一次公开 URL 端到端复测。

归档与复现

website/V0、website/V1 与 task3/v2/website 保存三个独立版本；evaluation/ 保存 rubric、人工评分、AI Judge prompt、三个原始 Judge 输出、截图和测试结果；prompt_appendix/ 保存提示词、few-shot 示例、RAG 检索记录、修改日志与失败尝试。

> 最终提交前检查：确认 report.pdf、prompt_appendix.pdf、website/、evaluation/ 均已打包；确认 V0 文件哈希与冻结记录一致；确认三个 AI Judge 原始输出保持原样。