COMP5583 · Agentic Computing

# Aria's Sky Journal
# 三版本网站与智能体技术优化实验报告

中文版主报告 · 2026年10月28日

作者：Xinyue Liu（化名：Aria）
项目：个人作品集与课程笔记检索演示
实验版本：V0 基线；V1 In-context Few-Shot Learning；V2 Retrieval-Augmented Generation（RAG）

公开版本链接
V0：https://liuxinyue84-sketch.github.io/
V1：https://liuxinyue84-sketch.github.io/V1/
V2：https://liuxinyue84-sketch.github.io/V2/

本报告依据项目源码、提示词附录、版本迭代记录、固定评估规则、人工评分、独立 AI Judge 原始结果及公开网页测试记录编写。V0 保持冻结；V1 与 V2 均从 V0 独立派生。

# 1. 实验目标与 V0 基线

本实验围绕个人网站开展两种正式 LLM 技术优化，并以版本对照与证据评估技术效果。网站主题为 “Aria’s Sky Journal”，采用浅蓝水彩天空、低饱和配色、玻璃质感卡片与胶囊导航。访客可浏览个人经历、教育与学术成果、项目贡献、生活媒体，使用 Guestbook 留言，并主动控制舒曼《梦幻曲》的播放。

## V0 功能与约束

- 导航板块：Home、Highlights、Projects、Life、Guestbook。教育经历可展开，项目支持分类、查看详情和收藏；Life 支持媒体预览；留言与收藏采用前端本地存储。
- 课程笔记检索：在浏览器端加载课程知识材料，以 BM25 关键词方式检索片段并展示来源。该基线没有服务端或真实 LLM 调用。
- 视觉与内容提示词限定了个人网站定位、低饱和水彩视觉、桌面端可读交互、纯静态 HTML/CSS/原生 JavaScript，以及不得臆造或替换个人经历。

## V0 冻结与提示词留痕

V0 源码及静态资源归档于 website/V0，并有 SHA-256 清单用于确认冻结后未被 V1/V2 技术改动。最早的外部 AI 初始指令与后续修改记录收入 prompt_appendix/task1_v0。部分 Trae 原始逐轮历史未能导出，因此附录明确区分“原始提示词”和“根据可追溯记录重建的摘要”，不把重建内容冒充逐字原文。

## 实验设计原则

V1 的自变量是 Few-shot 示例引导的组件结构生成；V2 的自变量是 RAG 检索链路。V1、V2 均独立从冻结 V0 出发，保留同一套个人事实与作业范围。评估规则在版本比较中固定；后续补充的五维人工评分作为独立的补充评价，不替代任务 2 的四项官方 AI Judge rubric。

# 2. V1：In-context Few-Shot Learning

V1 将少样本上下文学习用于网页生成：提示中提供经过抽象的开源组件与页面骨架范例，要求模型学习信息架构、排版和交互范式，不复制范例的个人资料、文案或身份。迭代从组件层逐步推进到整页骨架，避免仅调整配色而无法证明技术影响。

## Few-shot 输入材料与迭代

迭代 1–6：组件架构样本。 记录了 8 个来源：al-folio、Shaoyan Liu academic-homepage、Jiya Batra ArtPortfolio-jtc、Michael Kolesidis 个人站、Scrapbook Portfolio（aalinchen）、Photography Wall（Gabriel-Dalton）、Korbinian Möller 模板、Hitesh Nandakumar 作品集。示例归纳导航、作品展示、展开详情与能力呈现的结构规则。
迭代 7：页面骨架筛选。 采用 Ladvace/astro-bento-portfolio、codewithsadee/vcard-personal-portfolio、chrstnvi/zine-moskovskaya-excursia；弃用 vivek9patel/vivek9patel.github.io、Cveinnt/LiveTerm、hackclub/scrapbook、rammcodes/Dopefolio。最终选择“左侧身份与导航栏 + 右侧内容窗口”，因为它改变页面阅读模型且保留内容可发现性。
迭代 10：Life 图墙。 比较 Grid、Collage、Justified、Masonry、Slideshow 等画廊模式，参考 SmugMug、60 Minute Sites、mediagallery.org、master-addons masonry 方案，以及 Justified-Gallery、flickr-justified-gallery 等实现。
迭代 9、11、12：未引入新样本；迭代 12 沿用教育经历按需展开与技能可见的范式。来源记录见 reference_patterns.md、few_shot_examples_revision7.md、gallery_pattern_sweep.md。

## 模型输出与可观察变化

- 页面外壳由 V0 的纵向平铺内容重构为常驻档案侧栏和章节内容窗口；项目故事、教育展开、Life 图墙等采用对应的组件结构。
- 页面的主要个人内容继承 V0。V1-R12 的内容一致性记录比较了 48 组文案，报告为零差异、零结构错误。
- V1-R12 桌面端 E2E 记录为 35/35

检查通过、无页面或控制台错误；涵盖导航、轮播、教育/项目展开、筛选、收藏、媒体、视频、音乐和留言空输入校验。

## 失败尝试与权衡

早期迭代主要改变颜色、间距和局部卡片，页面仍像 V0，无法体现 Few-shot 对结构的作用；后续改用整页骨架示例并替换主要容器。代价是布局层级更复杂，且 Guestbook 有效提交、长度限制、全面移动端与对比度审计仍缺少同等强度的证据。

V1 部署：https://liuxinyue84-sketch.github.io/V1/。生成提示、示例、版本输出和逐轮改动记录保存在 prompt_appendix/task3_v1。

# 3. V2：前端可演示的 RAG

V2 完全从冻结 V0 独立派生，只升级课程笔记问答板块；没有复制 V1 的时间线、skill-chip 或页面骨架。静态 GitHub Pages 无法安全保管 API 密钥，也没有后端代理，因此该版本不调用外部 LLM API。它展示的是可审计的前端 RAG 模拟工作流，回答由确定性检索、过滤与摘要规则组织，不应描述为真实 LLM 生成。

### RAG 链路

- 知识库：将课程笔记、论文及项目材料结构化为主题标题、原文段落和来源信息，数据存储于前端 JavaScript。
- 召回：用户输入 query 后执行 BM25 关键词检索，返回多条候选片段；原始命中保留在参考区供核查。
- 相关性与排序：标题门控优先要求标题直接对应主题；在通过门控的候选中，以 baseConceptScore 对定义/概述类标题加权、对对比/偏置/变体类标题降权。正文偶然出现关键词的噪声仍可在证据区查看，但不进入答案。
- 答案与引用：从有效片段提炼简洁英文回答，并将引用编号放在相应句末；如果没有有效相关片段，统一显示资料不足提示。每条子句须与其引用片段一致，防止跨主题拼接公式或结论。

### 普通访客界面

页面呈现简洁的 “Explore my notes” 查询界面、Answer 卡片及默认收起的 “View Retrieved Reference Materials” 折叠区。访客主动展开后可以查看经过清洗的片段和来源；内部 prompt、开发备注与 KB 编号不直接暴露。预设问题用于覆盖课程主题，另有模糊和超出知识库范围的输入以验证回退行为。

### 技术边界

该实现适合展示“召回—相关性筛选—证据引用—无资料回退”的实验流程，不代表具备语义向量检索或通用自然语言理解能力。关键词召回和标题规则仍可能漏掉同义表达、较长概念解释或跨语言术语；非真实生成也限制答案的语言自然度与开放式综合能力。

# 4. V2 关键迭代与实测证据

本版本围绕检索结果与答案质量进行多轮通用逻辑修正，避免为单条 query 写专属答案或特例。每一阶段的 prompt、检索证据、失败现象和代码变化保存在 task3/v2 及提交附录。

## 关键迭代过程

- 修复检索与生成分支脱节：只要存在有效片段，Answer 必须生成；仅当有效片段数为零时显示固定英文不足提示。
- 清理访客界面：移除内部 prompt 显示和中文调试快捷项；原始证据默认折叠，清洗 Markdown、KB 标号与公式残留。
- 从“字面命中即回答”改为通用标题门控和二次排序：保留全部召回用于作业证据，仅以主题直接对应、标题概念得分较高的条目生成答案。
- 统一答案格式：总起定义加解释性分点，句末引用；支持中文查询与英文术语匹配，噪声留在证据区但过滤出答案。
- 增加来源一致性检查：每个答案句子、公式和结论都必须由其标注的引用支持，剔除混入的其他模型公式或旁支信息。

## 公开端到端测试

| 测试范围 | 结果 | 说明 |
| --- | --- | --- |
| RAG 问答 | 9/9 通过 | 公开 GitHub Pages；RAG、MapReduce、memory、tool use、中文 agent、CNN、MCP、模糊及越界查询；验证引用、折叠证据与回退 |
| 非 RAG 页面 | 13 项通过 | 导航、教育展开、4 个项目、详情、筛选、收藏、Life 媒体、图片预览及 Guestbook 表单 |
| 控制台 | 1 项 404 | 非 RAG 测试发现一个资源 404；记录称来源与影响未定位，不能声称无缺陷 |
| 回归检查 | 28 query / 10 invariants | 用于验证一般检索与答案规则，而非只覆盖单一问题 |

## 实测位置与保留限制

测试环境为公开 V2 URL 的桌面视口 1512×1000。RAG 九项记录报告全部通过且无控制台错误；非 RAG 页面清单报告 13 项通过，但存在一项 404。另有 28-query/10-invariant 的本地回归记录。以上结果支持代表性桌面任务，不证明任意 query 语义正确、页面跨浏览器无障碍或刷新/新会话后的所有持久化行为。

公开 V2：https://liuxinyue84-sketch.github.io/V2/。证据见 task3/v2/evaluation/e2e_results_v2.json、nonrag_public_e2e.json、回归脚本及截图。

# 5. 固定评估规则与独立 AI Judge

任务 2 官方 Judge rubric 固定为四项指标：Content Completeness & Clear Contribution（30%）、Navigation & Task Completion（25%）、Readability & Visual Consistency（25%）、Interaction Robustness（20%）。Judge 每项按 0–5 评分并按权重换算；分别使用独立空白会话，只提供评分标准和网页证据，不提供人工评分。

| 版本 | 内容 /5 | 导航 /5 | 可读性 /5 | 稳健 /5 | AI Judge 报告总分 |
|---|---|---|---|---|---|
| V0 | 5 | 4 | 3 | 4 | 81/100 |
| V1 Few-shot | 5 | 4 | 4 | 4 | 85/100* |
| V2 RAG 重测 | 5 | 5 | 4 | 4 | 91/100 |

*V1 原始 Judge 输出分项为 5、4、4、4。按 rubric 的 30/25/25/20 权重计算为 30+20+20+16=86，而原始 JSON 的 weighted_total 写 85。报告保留原始报告值 85，并明确标注按分项重算为 86；没有改写原始 Judge 输出。

### Judge 结论摘要

- V0：认为核心内容与贡献完整，主要桌面交互多数通过；MapReduce 检索排序和有限视觉证据拉低结果。
- V1：认可 48 组内容一致性、35/35 桌面 E2E 与结构重构；有效留言提交、长度边界及完整移动端证据仍不足。
- V2：重测证据涵盖 9 项 RAG 和 13 项非 RAG 检查，导航从早期证据所支持的 3/5 升到 5/5；视觉与稳健性仍各为 4/5，受单项 404、桌面视口和持久化覆盖限制。

AI 原始输出归档：V0/V1 位于 coursework/evaluation；仅保留 V2 最新重测原始输出于 task3/v2/evaluation/ai_judge_raw_output_rerun_2026-10-28.md。早期 V2 Judge 结果不纳入当前报告比较。

# 6. 人工补充评分与人机对照

人工补充评分采用用户确认的五维加权点数表：Content /20、Experience /20、Technique /30、Robustness /20、Evidence /10。此表由人工完成，和四项官方 Judge rubric 的分数口径不同，不能把列值直接与 AI 的单项 0–5 分比较。

| 版本 | 内容 /20 | 体验 /20 | 技术 /30 | 稳健 /20 | 证据 /10 | 人工总分 |
|---|---|---|---|---|---|---|
| V0 | 18 | 15 | 23 | 16 | 7 | 79 |
| V1 Few-shot | 19 | 18 | 27 | 18 | 8 | 90 |
| V2 RAG | 19 | 17 | 28 | 18 | 9 | 91 |

## 人机对照（均为各自口径的总分）

| 版本 | 人工补充分 | 官方 AI Judge | 差值与解释 |
|---|---|---|---|
| V0 | 79/100 | 81/100 | AI 高 2 分；AI 认为内容完整，人工更保守评估体验与证据。 |
| V1 Few-shot | 90/100 | 85/100* | 人工高 5 分；人工认可结构和体验提升，Judge 对有效留言及移动端证据缺口较保守。 |
| V2 RAG | 91/100 | 91/100 | 总分一致；Judge 导航给 5，人工给 4，其他维度差异抵消。 |

## 解释与局限

人工评分更强调版本的主观体验、技术完成度和归档证据；AI Judge 按四项固定 rubric 和当次可见证据给分，因此能独立复核但受证据包完整性、截图视口及测试覆盖影响。V2 总分相同不代表逐项判断一致；V1 的 85/86 分差异是原始 AI 输出内部算术不一致，已公开保留。五维人工表是用户确认的补充量表，不应伪称为原任务 rubric。

# 7. 结论、权衡与提交归档

三版本人工补充总分为 V0 79、V1 90、V2 91；官方独立 AI Judge 结果为 V0 81、V1 原始报告 85（分项重算 86）、V2 最新重测 91。两种评分均显示优化版本整体表现更高，但分数提升需结合页面与功能证据解释。

## 主要结论

- V1 的主要贡献是将 Few-shot 示例落实为可观察的页面骨架和组件结构变化，并用内容一致性与 E2E 记录支撑“个人信息保留、结构显著变化”。
- V2 的主要贡献是把原有关键词检索扩展为有相关性筛选、证据折叠、来源引用及资料不足回退的 RAG 演示链路。
- V1、V2 解决目标不同：V1 优化整体信息架构与浏览体验；V2 聚焦知识问答的可追溯性与证据边界。静态前端限制使 V2 不能提供真实 LLM 的开放式生成。

## 尚存限制与诚实披露

- 公开非 RAG E2E 有一项 404，尚未定位资源与影响；桌面之外的响应式与辅助技术行为没有充分验证。
- V2 代表性问题和 28-query 回归不等于任意查询正确；BM25/标题规则会有漏召回、误排序和翻译不自然风险。
- 历史 Trae 对话存在未导出部分，须以附录标注的重建稿作为有限记录，不能声称已保存全部原始对话。

## 交付结构

website/：V0、V1、V2 独立源码及资源；evaluation/：rubric、人工评分、AI Judge prompt 与原始输出、公开/本地测试结果和截图；prompt_appendix/：V0 原始/重建 prompt、Few-shot 样本、模型输出、RAG 输入和关键迭代；report.pdf：本中文版主报告。各版本 README 说明本地运行方式；公开地址列于首页。补充评分文件保存了人工总分，但 V0/V1 的逐指标支撑实例尚未完整填写；本报告不代写成用户的原始评语。

最终检查重点：确认归档包内三个网站版本和素材均齐全；原始 Judge 输出未被改写；V2 只引用 2026-10-28 最新重测；V0 冻结哈希保持一致。